

# RBM and DBN

赵惜墨


哈尔滨工业大学  
计算机学院  
智能技术与自然语言处理实验室

November 6, 2013

# 优点

- 1 保留了 bp 利用梯度方法调整权重的高效性、简单性
- 2 学习  $P(image)$  而不是  $P(label|image)$

# belief nets




- 1 置信网由一个具有随机变量的有向图构成
- 2 通过观测可见节点，解决以下两个问题
  - 1 推理问题：解决未观察到的节点的状态
  - 2 学习问题：通过调整可见节点相互之间的关系使网络产生更正确的观测变量

# 表示、学习

logistic belief net 由二元随机变量组成。

$$p(s_i = 1) = \frac{1}{1 + \exp(-b_i - \sum_j s_j w_{ji})}$$


$$\Delta W_{ji} = \epsilon s_j (s_i - p_i)$$



# explaining away


即使两个隐含变量独立，在两个变量都能影响到的事件上，它们也能变得相关。

发生地震减弱了发生卡车把房子撞了



explaining away 使有向图推理更困难了。

# 一次学习一层参数所带来的问题



- 为了学习  $W$  (权重), 需要学习第一层隐含层的后验分布

问题 1 由于 “explaining away”, 学习会变得非常复杂

问题 2 后验既依赖于先验也依赖于似然, 所以为了学习 ( $W$ ), 需要知道更高层的参数, 所有的权重都相关。

# 可以采用的学习方法


- MCMC: 费时
- 变分: 不准确

# DBN 所带来的突破

- 1 为了高效的学习，需要一次学一层。但是在假设隐含变量独立的情况写学习效果不好。
  - 隐含变量后验分布不独立导致对于非线性模型的推理十分的困难。
  - 在学习的过程中，算法在隐含层中寻找独立的解释，但是实际情况并非如此。
- 2 为了解决这些问题，引入了无向图模型。



# RBM



- 对于连接进行限制，只有一层
- 隐含层之间没有联系
- 给定可见节点，隐含层间节点相互独立

## 能量

$$E(v, h) = - \sum_{i,j} v_i h_j w_{ij}$$

$$-\frac{\partial E(v, h)}{\partial w_{ij}} = v_i h_j$$

# 能量 -> 概率


- 1 每一个可能的可见节点和隐含节点的组合都有一个能量
- 2 能量决定概率

$$p(v, h) = \frac{e^{-E(v, h)}}{\sum_{u, g} e^{-E(u, g)}}$$

- 3 可见节点的概率是所有含有该可见节点的组合的加和


$$p(v) = \frac{\sum_h e^{-E(v, h)}}{\sum_{u, g} e^{-E(u, g)}}$$

## MLE learning for RBM



$$\frac{\partial \log p(v)}{\partial w_{ij}} = \langle v_i h_j \rangle^0 - \langle v_i h_j \rangle^\infty$$


## quick way



- 从观测节点开始
- 更新隐含节点
- 重建可见节点
- 再次更新隐含节点

$$\Delta w_{ij} = \epsilon (\langle v_i h_j \rangle^0 - \langle v_i h_j \rangle^1)$$


## 例子



# 训练

- 1 先训练一个隐含层，从可见层直接接收数据
- 2 在将隐含层的输出作为下一层的可见节点，在进行训练

# 产生数据



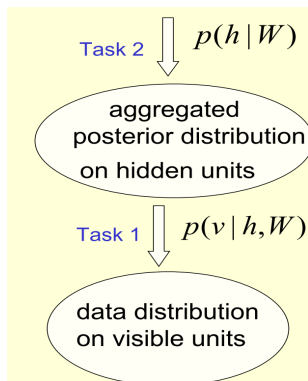
得到数据

- 在最上层进行 Gibbs sampling, 得到  $h_2$
- 对于其他层, 根据分布  $P(h^{k-1}|h^k)$  进行采样
- 最后得到的  $x = h^0$  即为所得

最后几个不是产生式模型的一部分, 只是用来进行 inference 的



# 为什么学习方法有效



- RBM 将数据分布转移到隐含层分布
- 将任务转化成两步：学习  $P(h|W), P(v|h, W)$
- 通过第二步 modeling 数据更容易，因为其更贴近 RBM 所能 model 的
- RBM 能表示为  $P(v) = \sum_h p(h)p(v|h)$ ，对于  $P(h)$  提高，自然可以提高  $P(v)$

## 例子

